

BART



진행 상태

진행 중

Abstract

보통 사전학습 언어모델은 BERT처럼 이해 중심이거나 GPT처럼 생성 중심으로 나뉜다.

BART는 이를 일반화한 모델로, 텍스트를 노이즈로 훼손한 뒤 원문을 복원하는 방식으로 학습한다. 아키텍처는 Transformer 기반이며, 인코더는 BERT처럼 양방향, 디코더는 GPT와 구조를 갖는다.

학습 시 여러 노이즈 기법을 실험했는데, 문장 순서 섞기와 in-filling에서 가장 좋은 성능을 얻었다.

실험 결과로는

- GLUE와 SQuAD에서는 RoBERTa와 동등한 성능,
- 요약·대화·질의응답 같은 생성 과제에서는 새로운 최고 성능(ROUGE 최대 +6),
- 기계번역에서는 역번역보다 BLEU +1.1 개선 효과가 있었다.

결론적으로 BART는 단순한 구조임에도 불구하고 이해와 생성 모두에 강력한 성능을 보이며, 다양한 사전학습 방식을 포괄할 수 있는 범용 프레임워크임을 알 수 있다.

Introduction

최근 NLP에서 Self-supervised **학습**이 큰 성과를 내고 있다. 그중 가장 성공적인 방법은 Masked Language Model 기반의 autoencoding **기법**으로, 일부 단어를 masking하여 원문을 복원하는 방식이다. 이후 연구들은 마스킹 분포, 예측 순서, 문맥 활용 범위를 개선했으나, 특정 태스크에만 최적화되는 한계가 있었다.

이를 해결하기 위해, 논문에서는 **BART**를 제안한다. BART는 Bidirectional + Auto-Regressive Transformer 구조를 결합한 **시퀀스-투-시퀀스 기반 노이즈 제거 모델**이다. 학습은 (1) 임의의 노이즈로 텍스트를 훼손, (2) 원문 복원 학습 두 단계로 진행된다. 아키텍처는 단순한 Transformer NMT 구조이지만,

- 인코더는 BERT처럼 양방향,
- 디코더는 GPT처럼 좌→우 구조를 취하며,

→ 다양한 사전학습 기법을 일반화할 수 있다.

특히 BART는 **노이즈 적용 방식의 유연성**이 장점이다. 문장 순서 섞기, 스펠 단위 인필링(in-filling) 등 다양한 변형을 허용하며, 이는 BERT의 단어 마스킹과 문장 예측을 확장하여 **길이·구조 변환까지 모델이 학습하도록 만든다**.

실험 결과

- GLUE, SQuAD: RoBERTa와 동등한 성능
- 요약·대화·질의응답 등 생성 과제에서 새로운 SOTA 달성

또한, 번역 파인튜닝 방식으로 BART 위에 Transformer 레이어를 쌓아, 외국어 → 노이즈 처리된 영어로 매핑하게 하여 **사전학습된 타겟 언어 모델**로 활용 가능함을 보였다.

마지막으로 ablation study를 통해 기존의 다양한 사전학습 기법들을 BART 프레임워크 내에서 재현, 데이터 및 최적화 요인을 통제된 비교를 수행하였다. 그 결과, BART가 다양한 Task에서 가장 안정적이고 강력한 성능을 보였다.

Model

Architecture

BART는 표준 sequence-to-sequence Transformer 아키텍처를 사용한다. 다만 GPT를 따라 ReLU 활성화 함수 대신 GeLU를 사용한다는 점이 다르다.

모델 크기에 따른 구조는 다음과 같다

- **Base 모델**: 인코더와 디코더 각각 6개 층 사용
- **Large 모델**: 인코더와 디코더 각각 12개 층 사용

구조적으로는 BERT와 유사하지만 두 가지 차이가 있다.

1. 디코더의 각 층은 인코더의 마지막 은닉층에 대해 Cross Attention을 수행한다.
2. BERT는 단어 예측 전에 추가적인 피드포워드 네트워크를 사용하지만, BART는 그렇지 않다.

결과적으로 같은 크기의 BERT 모델보다 **약 10% 더 많은 파라미터**를 사용한다.


Pre-training BART

보통 autoencoding 모델들은 특정한 노이즈 방식에 맞춰 학습하도록 설계된다.

하지만 BART는 훨씬 더 일반적인 방법을 사용한다. 문서를 훼손한 뒤 원래 문서를 복원하는 과정을 통해 학습하며, 디코더 출력과 원문 사이의 Cross-Entropy를 최소화하는 방식으로 최적화한다.

이를 검증하기 위해 기존에 사용되던 여러 노이즈 방식뿐 아니라 새로운 변환 기법까지 실험을 진행했다.

그 결과, BART는 단순히 언어 모델로서 동작할 수 있을 뿐만 아니라 다양한 형태의 문서 훼손에도 적용될 수 있음을 알 수 있다.



1. Token Masking

- BERT와 동일하게 입력에서 임의의 토큰을 골라 *MASK]로 바꾼다.

2. Token Deletion

- 랜덤 토큰을 아예 삭제한다.
- Token Masking과 달리 모델이 어떤 위치가 빠졌는지까지 스스로 추론해야 한다.

3. Text Infilling

- 여러 개의 연속된 span을 골라 하나의 [MASK]로 대체한다.
- 이 과정은 모델이 얼마나 많은 토큰이 빠졌는지까지 추론하도록 만든다.

4. Sentence Permutation

- 문서를 문장 단위로 나눈 뒤, 순서를 무작위로 섞는다.

5. Document Rotation

- 문서에서 임의의 토큰 하나를 골라 그 토큰이 문서의 시작이 되도록 문서를 회전시킨다.
- 이를 통해 모델은 문서의 올바른 시작 위치를 파악하도록 학습한다.

Fine-tuning BART

3.1 Sequence Classification (시퀀스 분류)

- 입력을 인코더와 디코더 모두에 넣음.
- 디코더의 마지막 토큰의 최종 hidden state를 가져와 새로운 다중 클래스 분류기에 전달.
- BERT의 [CLS]토큰과 유사하지만, BART는 입력 끝에 추가 토큰을 넣어 디코더가 전체 입력을 참고할 수 있도록 함.

3.2 Token Classification (토큰 분류)

- 예: SQuAD에서 답변 위치 예측.
- 전체 문서를 인코더와 디코더에 넣음.
- 디코더의 각 단어의 top hidden state를 사용하여 토큰 단위 분류 수행.

3.3 Sequence Generation (시퀀스 생성)

- BART의 autoregressive 디코더 특성을 활용.
- 추상적 질의응답(QA), 요약(summarization) 같은 생성 과제에 직접 fine-tuning 가능.
- 인코더 입력: 원본 시퀀스
디코더 출력: 새로운 시퀀스 생성 (입력 내용을 조작·변형).

3.4 Machine Translation (기계 번역)

- 영어 번역을 목표로 BART 전체(인코더+디코더)를 **하나의 사전학습된 디코더**처럼 사용.
- 방법:
 1. BART의 인코더 임베딩 레이어를 새로운 무작위 초기화 인코더로 교체.
 2. 새 인코더는 외국어 단어를 BART가 영어로 복원할 수 있는 입력으로 변환하도록 학습.
 3. 새 인코더는 별도의 어휘집(vocabulary)을 가질 수 있음.
- 학습 단계:
 - **1단계:** 대부분의 BART 파라미터는 고정하고, 새 인코더 + 포지셔널 임베딩 + 첫 레이어 self-attention 입력 projection만 학습.
 - **2단계:** 전체 파라미터를 소수 iteration 동안 fine-tuning.

Comparing Pre-training Objectives

1. Pre-training

- **Language Model (GPT 방식):** 왼쪽→오른쪽
- **Permuted LM (XLNet 방식):** 랜덤 순서로 토큰 생성
- **Masked LM (BERT 방식):** 토큰 일부를 [MASK]로 바꾸고 예측
- **Multitask Masked LM (UniLM 방식):** 다양한 self-attention mask 조합
- **Masked Seq-to-Seq (MASS 방식):** 긴 span(50%) 마스킹 후 seq2seq로 예측

2. 실험한 다운스트림 과제들

- **SQuAD:** 추출형 질의응답
- **MNLI:** 문장 관계 분류
- **ELI5:** 장문 생성형 질의응답
- **XSum, CNN/DM:** 뉴스 요약
- **ConvAI2:** 대화 응답 생성

3. 결과 및 인사이트

- 과제별 성능 차이 큼 → 어떤 목적이 좋은지는 task에 따라 다름
- Token masking이 핵심 → 단순 문장 순서 바꾸기만 하는 방식은 성능 낮음
- 왼쪽→오른쪽 학습 중요 → 생성(task)에서 큰 효과
- 양방향 인코더 필요 → SQuAD 같은 분류형 task에서 결정적
- 순수 LM이 ELI5에 가장 강함 → 입력 제약이 약한 자유 생성에 더 적합
- BART가 전반적으로 가장 안정적 성능 → 특히 text-infilling 방식이 다수 과제에서 우수

Large-scale Pre-training Experiments

	SQuAD 1.1 EM/F1	SQuAD 2.0 EM/F1	MNLI m/mm	SST Acc	QQP Acc	QNLI Acc	STS-B Acc	RTE Acc	MRPC Acc	CoLA Mcc
BERT	84.1/90.9	79.0/81.8	86.6/-	93.2	91.3	92.3	90.0	70.4	88.0	60.6
UniLM	-/-	80.5/83.4	87.0/85.9	94.5	-	92.7	-	70.9	-	61.1
XLNet	89.0 /94.5	86.1/88.8	89.8/-	95.6	91.8	93.9	91.8	83.8	89.2	63.6
RoBERTa	88.9/ 94.6	86.5 /89.4	90.2 / 90.2	96.4	92.2	94.7	92.4	86.6	90.9	68.0
BART	88.8/ 94.6	86.1/89.2	89.9/90.1	96.6	92.5	94.9	91.2	87.0	90.4	62.8

Discriminative Tasks

- 평가 대상:
 - SQuAD (질의응답)
 - GLUE 벤치마크 (문장 분류 및 유사도 평가)
 - 포함된 대표 과제:
 - CoLA (문법적 수용성)
 - SST-2 (감정 분석)
 - MRPC (문장 유사도 판별)
 - STS-B (문장 의미 유사도 점수화)

- QQP (중복 질문 판별)
- MNLI, QNLI, RTE (자연어 추론)
- WNLI (참/거짓 추론)
- 비교 대상:
 - RoBERTa
- 결과 요약:
 - BART와 RoBERTa는 거의 유사한 성능을 보임.
 - 대부분의 과제에서 차이는 미미함.
 - 따라서 BART의 생성 성능 향상이 분류 성능 저하를 초래하지 않음을 확인.

	CNN/DailyMail			XSum		
	R1	R2	RL	R1	R2	RL
Lead-3	40.42	17.62	36.67	16.30	1.60	11.95
PTGEN (See et al., 2017)	36.44	15.66	33.42	29.70	9.21	23.24
PTGEN+COV (See et al., 2017)	39.53	17.28	36.38	28.10	8.02	21.72
UniLM	43.33	20.21	40.51	-	-	-
BERTSUMABS (Liu & Lapata, 2019)	41.72	19.39	38.76	38.76	16.33	31.15
BERTSUMEXTABS (Liu & Lapata, 2019)	42.13	19.60	39.18	38.81	16.50	31.27
BART	44.16	21.28	40.90	45.14	22.27	37.25

Generation Tasks

- 평가 방식:
 - BART를 표준 시퀀스-투-시퀀스(seq2seq) 모델로 fine-tuning.
 - 입력 텍스트 → 출력 텍스트 변환.
- 학습 세부 사항:
 - **Loss 함수**: Label-smoothed cross entropy
 - smoothing 파라미터 = 0.1
 - **생성 시 설정**:
 - Beam size = 5
 - Beam search 중 중복 trigram 제거
 - min-len, max-len, length penalty → 검증 데이터셋 기준으로 최적화

- **결과 요약:**

- BART는 다양한 생성 과제에서 안정적이고 품질 높은 출력을 생성.
- 추론 시 중복 방지와 길이 조정으로 자연스러운 결과 도출.

Qualitative Analysis

BART는 요약 과제에서 기존 SOTA대비 성능 향상을 보여준다.

생성된 요약문은 전반적으로 유창하고 문법적으로 올바른 영어로 작성되었으며, 입력 문장을 거의 그대로 복사하지 않고 새로운 표현으로 재구성하는 높은 abstractive을 보였다.

BART는 사전학습을 통해 자연어 이해(NLU)와 자연어 생성(NLG) 능력을 동시에 강화한 모델임이 확인되며, 이는 추론적이고 창의적인 요약 생성으로 이어진다. 그러나 사실적 일관성을 유지하기 위한 보완이 필요하다는 한계도 존재한다.