

Diffusion

🌀 진행 상태 **진행 중**

GAN, VAE 등 다양한 생성 모델이 좋은 품질을 내고있다.

이 논문은 원본 데이터에 점진적으로 노이즈를 추가해 망가뜨리는 Diffusion 과정을 학습한 뒤, 이 과정을 거꾸로 되돌려 순수한 노이즈에서부터 원본 데이터를 복원해내는 Ddiffsion 모델에 주목한다.

우선 모델의 두 가지 핵심 과정에 대해 알아보자

Forward Process

데이터를 노이즈로 만드는 순방향 과정이다.

우선 이 과정은 고정되어 있고 학습되지 않는다. 원본 데이터 x_0 에 정해진 규칙에 따라 점진적으로 가우시안 노이즈를 추가하여 T 단계에 걸쳐 완전한 노이즈 x_T 로 만든다.

$$q(x_t | x_{t-1}) := \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

각 단계 t 에서 이전 단계의 데이터 x_{t-1} 에 분산 β_t 만큼의 노이즈를 추가하여 x_t 를 생성한다.

이 과정에서의 장점은 중간 단계를 모두 거치지 않고도 원본에서 특정 시점의 노이즈 데이터를 한 번에 계산할 수 있다는 것이다. 따라서 훈련 시에 무작위로 t 를 뽑아 효율적으로 학습할 수 있다.

이 과정에서 각 스텝마다 추가되는 노이즈의 양 β_t 는 학습하지 않고 미리 정해진 상수로 고정했다. 이는 순방향 과정에서 학습할 파라미터가 없어지므로 전체 손실함수의 마지막 항인 L_T 는 훈련 중에 변하지 않는 상수가 되어 무시할 수 있다.

Backward Process

이 과정이 학습과정이다.

이번에는 순방향과 정반대로 노이즈 x_T 에서 시작하여 점진적으로 노이즈를 제거해 나가면서 원본 데이터 x_0 를 생성한다.

$$p_\theta(x_{t-1} | x_t) := \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

각 단계 t 에서 x_t 를 입력받아 이전 단계의 데이터 x_{t-1} 를 예측한다. 이 예측은 가우시안 분포를 따르고 모델은 이 분포의 평균과 분산을 학습한다.

다만 x_{t-1} 의 평균을 직접 예측하는 것 보다, x_t 를 만드는 데 사용된 원본 노이즈를 예측하도록 하는 것이 더 효과적이다. 왜냐하면 손실 함수를 실제 노이즈와 모델이 예측한 노이즈 사이의 MSE 형태로 간단하게 나타낼 수 있기 때문이다

Loss function

$$\mathcal{L} = \mathbb{E}_q \left[\text{KL}(q(x_T | x_0) \| p(x_T)) + \sum_{t>1} \text{KL}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t)) - \log p_\theta(x_0 | x_1) \right]$$

학습 목표는 Variational bound를 최적화하는 것이다.

각 단계 t에서 모델의 예측과 실제 정답 사이의 차이를 KL Divergence로 측정하는 형태가 된다.

즉 역방향 과정과 순방향 과정의 분포 차이(KL Divergence)를 최소화 하는 방식으로 이루어진다.

다만 위와 같은 손실 함수를 그대로 사용하지 않고 실제 훈련에서는 더 단순하고 실용적인 목적함수를 사용했다.

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

이 는 모든 단계 t와 데이터에 대해 (실제 노이즈 - 예측 노이즈)^2을 최소화하는 것이다.

노이즈가 적은 쉬운문제보다 노이즈가 많은 어려운 문제 즉, t가 큰 경우에 모델이 더 집중하게 할 수 있다.

Experiments

- T : 모든 실험에서 1000으로 설정
- β_t : 0.0001에서 0.02까지 선형적으로 증가하도록 고정
- 모델 : U-Net 아키텍처 기반, 시간 정보는 트랜스포머의 sinusoidal position embedding을 사용해 네트워크에 전달

Sample quality



Figure 3: LSUN Church samples. FID=7.89




Figure 4: LSUN Bedroom samples. FID=4.90

CIFAR10 데이터 셋에서 FID 스코어 3.17을 기록하며 당시의 대부분 모델에 비해 뛰어난 성능을 달성 또한 단순화된 손실 함수를 사용했을 때 품질이 더 좋았다.

Reverse process parameterization and training objective ablation

이미지의 평균을 예측하는 방식과 기존의 손실 함수와 결합했을 때보다
노이즈를 예측하는 방식과 단순화된 손실 함수를 결합했을 때 압도적으로 좋은 성능을 보였다.

또한 분산을 미리 정해진 상수로 고정했을 때 훨씬 안정적이고 좋은 결과를 얻었다.

Progressive coding

Diffusion 모델은 뛰어난 손실 압축기 역할을 한다

송신자가 수신자에게 이미지 x_0 를 전송하려할 때 이미지를 한 번에 보내는 대신 가장 노이즈가 심한 상태인 x_T 부터 시작해 점차 노이즈가 제거되는 순서로 각 단계에 필요한 정보를 순차적으로 전송한다. 수신자는 각 단계 t 에서 부분적인 정보만 받았음에도 불구하고, 이 정보만으로 최종 원본 이미지가 어떨지 계속해서 추정할 수 있다.

이 때 수신자가 받은 총 정보의 양 bits 를 rate가 하고 Distorsion을 원본 이미지와 추정한 이미지의 오차라 하자





Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a $[0, 255]$ scale. See Table 4 for details.

그래프의 초반부에서 왜곡이 급격하게 감소함을 알 수 있다.

즉 모델은 아주 적은 양의 정보량만으로도 이미지의 전체적인 모습을 빠르게 복원할 수 있다. 나머지 대부분의 비트는 사람이 거의 인지하지 못하는 미세한 디테일이나 노이즈를 수정하는 데 사용된다.



노이즈에서 이미지를 생성하는 과정을 보면, 처음에는 이미지의 전체적인 구조와 형태 등 큰 특징이 먼저 나타나고 점차 세부적인 디테일이 추가되는 것을 볼 수 있다.

즉 인간이 봤을 때 가장 중요한 시각 정보를 우선적으로 처리하고 복원하므로 높은 효율의 손실 압축기로 활용할 수 있다.

Interpolation



Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

두 이미지를 noisy space로 보내고 이 둘을 선형적으로 섞고 다시 이미지로 복원하는 방식으로 보간이 가능하다. 그 결과로 이미지의 여러 속성이 자연스럽게 변하는 고품질의 중간 이미지들을 생성할 수 있다. 노이즈를 더 많이 추가한 상태에서 보간하면 더 다양하고 창의적인 결과가 나타났다.

이러한 Diffusion 모델은 다음과 같은 장단점을 가진다.

장점

- 데이터 압축 능력을 이용해 전송효율을 높여 접근성 향상
- 라벨이 없는 방대한 데이터로부터 유용한 특징을 학습하여 이미지 분류나 강화 학습 등 다양한 후속 작업의 성능을 향상
- 예술과 같은 창의적인 분야에서 새로운 도구로 활용

단점

- 딥페이크와 같은 가짜 이미지, 영상을 이용해 악용될 수 있음
- 인터넷에서 수집된 데이터 셋의 편향을 학습하므로 기존의 편견이 더 강화될 수 있음
- 현재는 AI가 이미지를 탐지하는 기술이 있지만 생성 모델이 발전할수록 진짜와 가짜를 구별하기가 더 어려워질 것