

GAN

※ 진행 상태

진행 중

생성 모델은 딥러닝의 성공적인 결과를 보여주는 판별 모델과 다른 문제점을 가지고 있었다.

생성 모델은 MLE와 같이 특정 분포를 근사하여 추론하는 방식을 사용했었다.

이러한 방식은 수많은 확률적 계산을 이용해야하며, 데이터의 차원이 높아지면 거의 불가능에 가까운 계산이 필요하다.

이 논문은 새로운 학습 방법으로 적대적 신경망을 제안한다.

이 신경망의 예시로 위조지폐범과 경찰의 관계를 들어보자

- 생성자(Generator) : 위조지폐범
 - 목표 : 진짜와 구별할 수 없을 만큼 정교한 가짜 위조지폐를 만들어내는 것
 - 학습 : 경찰이 진짜라고 착각하게 만드는 방향으로 학습
- 판별자(Discriminator) : 경찰
 - 목표 : 진짜 지폐와 위조지폐범이 만든 가짜 위조지폐를 구별하는 것
 - 학습 : 지폐가 진짜인지 가짜인지 탐지하는 방향으로 학습

학습 과정은

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

1. 생성자가 노이즈 데이터를 생성한다.
2. 판별자가 이를 가짜라고 판별하면 생성자는 이에 대한 피드백을 받아 학습하고 더 알맞는 데이터를 생성한다.
3. 판별하는 더 정교해진 가짜 데이터와 진짜 데이터를 모두 보고 판별능력을 향상시킨다.
4. 이를 계속해서 반복하여 서로의 실력이 상승하도록 한다.

이러한 경쟁의 지향점은 판별자가 어떤 데이터가 들어오든 진짜일 확률을 50%로 예측할 때이다. 이 뜻은 생성자가 원본 데이터의 실제 분포를 거의 완벽하게 학습했다는 뜻이다.

이러한 방식은 기존 생성모델의 확률 계산을 우회한다. 직접적으로 확률 적분 문제를 푸는 것은 사실상 불가능하기 때문에 GAN은 이를 간접적으로 측정하는 것이다.


다만 발생할 수 있는 문제점이 있다.

학습 초반에는 생성자가 만든 가짜 데이터의 품질이 매우 낮으므로 판별자는 너무 쉽게 가짜임을 알아채고 $D(G(z))$ 값을 0에 가깝게 출력한다 이에 따라 기울기 소실 문제가 발생할 수 있다.

따라서 기존 목표인 $\min \log(1 - D(G(z)))$ 대신 $\max \log(D(G(z)))$ 를 목표로 학습 시킨다.

이를 통해 학습 초반에 더 큰 기울기를 얻으며 더 빠르게 학습을 진행할 수 있다.

이러한 과정을 시각화 해보면



(a) : 학습이 어느 정도 진행되어 생성자가 실제 데이터와 유사해졌고 판별자는 둘을 어느 정도 정확하게 분류하고 있다.

(b) : 실제 데이터 밀도가 높은 곳은 1에 가깝게 가짜 데이터 밀도가 높은 곳은 0에 가깝게 판별하며, 판별자가 데이터를 구별할 수 있도록 업데이트 된다.

- (c) : 판별가자 진짜라고 판단할 가능성이 높은 지역으로 생성자의 분포를 이동시킨다.
- (d) : 생성자와 판별자가 더 이상 개선될 수 없는 상태로 생성자 분포가 실제 데이터 분포와 같아진다.

실험에 사용한 데이터셋은

- MNIST: 흑백 손글씨 숫자 이미지 데이터셋
- TFD (Toronto Face Database): 흑백 얼굴 이미지 데이터셋
- CIFAR-10: 저해상도 컬러 사물 이미지 데이터셋

를 사용했다.


네트워크 구조에서

생성자는 활성화 함수로 ReLU와 Sigmoid를 섞어서 사용했고,
판별자는 활성화 함수로 Maxout을 사용하고 과적합을 방지하기 위해 Dropout을 적용했다.


Model	MNIST	TFD
DBN [3]	138 $\pm$ 2	1909 $\pm$ 66
Stacked CAE [3]	121 $\pm$ 1.6	2110 $\pm$ 50
Deep GSN [6]	214 $\pm$ 1.1	1890 $\pm$ 29
Adversarial nets	225 $\pm$ 2	2057 $\pm$ 26

다른 모델들과의 Parzen 윈도우 방식을 이용한 점수 비교 표이다.


기존 다른 모델들보다 월등히 뛰어나지 않지만 기존의 우수한 생성모델들에 뒤쳐지지 않는 수준의 결과를 낸다. 즉 이런 적대적 신경망의 잠재력이 있음을 알 수 있다.




a)



b)



c)



d)

위 그림에서 가장 마지막열은 5번째 열과 가장 가까운 훈련 데이터 예시이다. 이를 통해 알 수 있는 점은 모델이 훈련 데이터를 그냥 통째로 외워서 똑같이 그려내고 있지 않다는 점이다. 스타일은 비슷하지만 명백히 다른 이미지란 것을 확인할 수 있다.

다만 GAN의 단점 역시 존재한다.

- 생성된 데이터의 확률을 알 수 없다.

생성자가 특정 데이터 x 를 생성할 확률 $p_g(x)$ 값을 직접 계산 할 수 없다.

확률 분포로부터 새로운 샘플을 뽑을 수는 있지만, 특정 샘플이 얼마나 그럴듯한지를 확률 값으로 알려주지는 못한다.

- 학습 과정의 불안정성

판별자와 생성하는 학습 과정에서 동기화 되어야한다. 만약 두 모델의 균형이 깨지면 학습이 실패할 수 있다.

- Mode Collapse 현상

판별자를 충분히 업데이트하지 않은 채 생성자만 과도하게 훈련시키면 Mode Collapse가 발생할 수 있다.

생성자가 판별자를 속이는 가장 쉬운 하나의 방법만 찾아내어 다양한 노이즈를 입력해도 항상 비슷하거나 똑같은 결과물만 생성하는 현상이다.

결구 데이터의 다양성을 학습하지 못하고 하나의 결과에만 갇히게 된다.

GAN은 5가지 방법으로 확장될 수 있다.

1. 조건부 생성 모델

기존의 GAN이 무작위로 데이터를 생성했다면 여기에 조건을 추가하여 원하는 데이터를 생성하도록 제어할 수 있다.

2. Learned Approximate Inference

기존의 GAN은 노이즈(z)에서 데이터(x)로 가는 과정을 학습하는데, 이와 반대로 주어진 데이터(x)로부터 잠재 변수(z)를 예측하는 역방향 과정을 학습할 수 있다.

3. Modeling Conditionals

데이터의 일부가 주어졌을 때 나머지 부분을 예측하는 모델을 만들 수 있다.

4. Semi-Supervised Learning

라벨이 있는 데이터가 매우 적을 때 GAN을 활용하여 데이터의 특징을 스스로 학습하게 하여 이를 이용해 분류기의 성능을 향상시킬 수 있다.

5. Efficiency Improvements

학습 중에 생성자에게 입력으로 주는 노이즈를 단순한 정규분포가 아닌 더 나은 분포에서 샘플링하는 방법을 찾아 학습 효율을 높일 수 있다.