

SAM

⚙ 진행 상태

진행 중

NLP분야에서 하나의 범용적인 데이터로 사전 훈련을 시킨 후 다른 하위 task로 학습시켜 문제를 해결하는 방식을 SAM은 이미지 분할에 적용하려한다.

이 목표를 위해서 prompt Segmentation Task를 새롭게 정의했는데

- Points : 전경, 배경을 나타내는 점
- Box : 객체의 대략적인 위치를 나타내는 상자
- Mask : 대략적으로 칠해진 마스크
- Text : 고양이, 자동차와 같이 자유형식의 텍스트

와 같은 이미지에서 무엇을 분할 해야하는 지에 대한 정보인 Prompt를 이용한다.


SAM은 훈련 데이터의 각 이미지에 대해 가상의 프롬프트를 생성하고 모델이 예측한 마스크를 실제 정답 마스크와 비교하며 학습한다.

이렇게 훈련된 모델은 어떤 프롬프트에도 적절히 반응하는 능력을 갖추게 되며 추가적인 훈련 없이도 다양한 분할 작업을 프롬프트 엔지니어링을 통해 해결할 수 있다.

이러한 SAM의 특징은 멀티태스크 시스템과 차이점을 가진다

멀티태스크 시스템은 하나의 모델이 정해진 몇 가지 작업을 동시에 수행하도록 훈련되지만 SAM은 프롬프트 기반 분할이라는 단 하나의 일반적인 과제로 훈련된다.

이러한 접근법은 모델 설계에서는 예측하지 못했던 새로운 작업에도 활용될 수 있고 사람과의 상호작용 뿐만아니라 다른 알고리즘 시스템과도 조합 될 수 있기 때문에 활용 범위가 훨씬 넓다.



SAM의 아키텍처 부분을 살펴보자

- 이미지 인코더

이미지를 입력 받아 분할 작업에 사용할 수 있는 임베딩으로 변환한다.

사전 훈련된 ViT를 이용하여 MAE 방식으로 사용한다.

- 프롬프트 인코더

사용자의 다양한 프롬프트를 모델이 이해할 수 있는 임베딩으로 변환한다.

Point, Box : 위치 정보를 나타내는 위치 인코딩과 각 프롬프트 유형을 구하는 임베딩을 결합하여 표현

Text : 기존 CLIP 모델의 텍스트 인코더를 그대로 가져와 사용한다.

Mask : 합성곱 신경망을 이용해 임베딩으로 변환한 후 이미지 임베딩과 원소별로 더한다.

- 마스크 디코더

이미지 임베딩과 프롬프트 임베딩을 입력받아 최종 분할 마스크를 생성한다.

Transformer의 디코더 블록을 변경하여 사용했는데, Cross attention 매커니즘을 이용했다. 이러한 2개의 디코더 블록을 거치고 결과물을 MLP를 통해 분할된 객체가 포함될 확률을 계산하여 최종 마스크를 만든다.

다만 모호한 프롬프트에 대해 단 하나의 마스크만 출력하면 여러 가능한 객체들의 평균인 이상한 마스크가 생성될 수 있다.

따라서 SAM은 하나의 프롬프트에 대해 3개의 유효한 마스크를 동시에 예측하도록 설계되었다. 이러한 3개의 예측 마스크 중 실제 정답과 가장 Loss가 적은 단 하나의 마스크에 대해서만 역전파를 수행하여 학습한다.

하지만 인터넷에는 고품질의 분할 데이터가 부족했다. 그래서 11억개의 마스크가 있는 SA-1B데이터셋을 자체적으로 구축하기 위해 데이터 엔진을 개발 했다.

엔진의 구성은 다음과 같다.

1. Assisted-Manual Stage

전문 작업자들이 브라우저 기반의 대화형 분할 도구를 사용해서 마스크를 생성한다.

2. Semi-automatic Stage

1단계 데이터로 학습된 객체 탐지기를 이용해 눈에 잘 띄는 객체들의 마스크를 자동으로 생성하고 작업자들은 나머지 누락된 객체들만 추가로 라벨링한다.

3. Fully Automatic Stage

사람의 개입 없이 모델을 사용하여 데이터셋을 폭발적으로 확장한다. 이미지 전체에 32*32의 점 격자를 프롬프트로 입력하고 각 점에 대해 가능한 마스크 후보를 생성한다.

이러한 엔진으로 만들어진 SA-1B 데이터셋에 대해 살펴보자

- 이미지

3300X4950 픽셀의 초고해상도이고 접근성을 위해 1500픽셀로 짧은 쪽을 다운샘플링해서 배포했다. 이러한 이미지에서 얼굴과 차량 번호판은 흐림처리되어있다.

- 마스크

데이터셋에 포함된 11억 개의 마스크 중 99.1%가 데이터 엔진의 최종 단계에서 완전 자동으로 생성되었다.

이러한 마스크는 검증결과 94%의 마스크 쌍이 90%이상의 IoU를 기록했다. 이는 기존 연구에서 측정된 사람 작업자 간의 IoU 보다도 높은 수기로 자동 생성 되었지만 마스크의 품질이 뛰어남을 알 수 있다.

이러한 데이터들은 이미지당 평균 마스크가 100개로 다른 데이터셋들에 비해 월등히 많고 작거나 중간 크기의 객체 마스크를 더 많이 포함한다.




Figure 5: Image-size normalized mask center distributions.

COCO나 Open Images는 객체가 이미지 중앙에 몰려있는 반면 SA-1B는 이미지의 가장자리 까지 객체들이 더 고르게 분포한다.

	# countries	SA-1B		% images			mIoU at		mIoU at	
		#imgs	#masks	SA-1B	COCO	O.I.	1 point	3 points	1 point	3 points
Africa	54	300k	28M	2.8%	3.0%	1.7%	<i>perceived gender presentation</i>		<i>perceived skin tone</i>	
Asia & Oceania	70	3.9M	423M	36.2%	11.4%	14.3%	feminine	54.4 ± 1.7 90.4 ± 0.6	1	52.9 ± 2.2 91.0 ± 0.9
Europe	47	5.4M	540M	49.8%	34.2%	36.2%	masculine	55.7 ± 1.7 90.1 ± 0.6	2	51.5 ± 1.4 91.1 ± 0.5
Latin America & Carib.	42	380k	36M	3.5%	3.1%	5.0%	<i>perceived age group</i>		3	52.2 ± 1.9 91.4 ± 0.7
North America	4	830k	80M	7.7%	48.3%	42.8%	older	62.9 ± 6.7 92.6 ± 1.3	4	51.5 ± 2.7 91.7 ± 1.0
high income countries	81	5.8M	598M	54.0%	89.1%	87.5%	middle	54.5 ± 1.3 90.2 ± 0.5	5	52.4 ± 4.2 92.5 ± 1.4
middle income countries	108	4.9M	499M	45.0%	10.5%	12.0%	young	54.2 ± 2.2 91.2 ± 0.7	6	56.7 ± 6.3 91.2 ± 2.4
low income countries	28	100k	9.4M	0.9%	0.4%	0.5%				


SA-1B 데이터셋의 편향성을 분석했다.

지역적 분포, 소득 수준 별 분포등을 참고하여 다른 소위된 분포에서도 다른 모델들에 비해 더 많은 양의 데이터를 담고 있다는 점을 보여준다

SAM모델을 이용할 때에서 성별, 연령대, 피부색과 같은 부분에서 차이가 존재하는지 공정성을 확인했다. 물론 일부 편향이 존재하기는 했지만 전체적으로 크게 부정적인 성능저하는 나타나지 않았다.

Zero-Shot Transfer Experiments

SAM을 추가적인 훈련 없이 오직 프롬프트 엔지니어링만으로 다양한 신규작업에서 제로샷 성능을 보자



(a) SAM vs. RITM [92] on 23 datasets

1. 단일 점으로 마스크 생성

이 과제에서는 본질적으로 모호성이 높다 하나의 점이 여러 객체를 동시에 가리킬 수 있기 때문이다.

mIoU 에서 SAM은 23개 데이터셋 중 16개에서 RITM보다 높은 성능을 보였다.

사람 평가에서는 mIoU에서 일부 RITM보다 낮게 나온 데이터 셋보다도 SAM은 마스크 품질이 훨씬 높았다. 즉 실제 사람이 보기에는 SAM이 생성한 마스크가 실제 사람이 보기에는 훨씬 더 정확하고 유효하다는 것을 의미한다.




Figure 10: Zero-shot edge prediction on BSDS500. SAM was not trained to predict edge maps nor did it have access to BSDS images or annotations during training.

method	year	ODS	OIS	AP	R50
HED [108]	2015	.788	.808	.840	.923
EDETR [79]	2022	.840	.858	.896	.930
<i>zero-shot transfer methods:</i>					
Sobel filter	1968	.539	-	-	-
Canny [13]	1986	.600	.640	.580	-
Felz-Hutt [35]	2004	.610	.640	.560	-
SAM	2023	.768	.786	.794	.928

Table 3: Zero-shot transfer to edge detection on BSDS500.

2. Zero-Shot Edge Detection

엣지 검출을 위해 이미지에 16*16의 점 격자를 프롬프트로 입력한다. 이를 통해 총 768개의 마스크를 예측하고 중복되는 마스크를 제거한 후 후처리 과정을 통해 엣지 맵을 생성한다.

SAM은 엣지 검출에서는 전혀 훈련되어있지 않지만 좋은 결과를 보여줬다. 다만 BSDS500 데이터셋에 특화되어 훈련된 SOTA 모델 보다는 성능이 낮았다.

하지만 초기 딥러닝 모델인 HED와 비교해서는 좋은 성능을 보였고 기존의 다른 제로샷 방법들보다는 좋은 결과를 보였다.

method	mask AR@1000						
	all	small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

Table 4: Object proposal generation on LVIS v1. SAM is applied zero-shot, *i.e.* it was not trained for object proposal generation nor did it access LVIS images or annotations.

3. Object Proposal Generation

이미지 내에 객체가 있을 만한 위치 후보군을 마스크 형태로 생성하는 과제이다.


LVIS 데이터 셋으로 직접 훈련된 ViTDet-H가 전반적으로 가장 좋은 성능을 보였다

하지만 SAM은 중형 및 대형 객체 혹은 희귀하거나 일반적인 빈도의 객체를 찾아내는 능력은 오히려 더 뛰어났다.

소형 객체 혹은 매우 빈번하게 등장하는 객체에서만 성능이 뒤쳐졌으므로 SAM 역시 이러한 작업에서 좋은 결과를 낸 것을 볼 수 있다.

method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5

Table 5: Instance segmentation results. SAM is prompted with ViTDet boxes to do zero-shot segmentation. The fully-supervised ViTDet outperforms SAM, but the gap shrinks on the higher-quality LVIS masks. Interestingly, SAM outperforms ViTDet according to human ratings (see Fig. 11).



4. Instance Segmentation

이미지에 있는 모든 객체를 개별적으로 식별하고 각 객체의 윤곽선을 픽셀 단위로 정확하게 구분해내는 과제이다.

Mask AP에서는 SAM 기반의 방식이 ViTDet에 근접하기는 했지만 약간 뒤쳐지는 성능을 보였다.

하지만 사람 평가를 진행하면 SAM이 생성한 마스크의 경계선이 더 깔끔해보이는 경우가 많았다.




Figure 12: Zero-shot text-to-mask. SAM can work with simple and nuanced text prompts. When SAM fails to make a correct prediction, an additional point prompt can help.

5. Text-to-Mask

자유 형식의 텍스트만으로 객체를 분할하는 과제이다.

기존에 수집한 마스크 데이터에 대해서 CLIP 이미지 임베딩을 추출하고 이를 이용해 SAM을 프롬프트로 학습시킨다.

시각적 결과에서 SAM은 바퀴와 같은 단순한 텍스트뿐만 아니라 '비버 이빨 모양 그릴'과 같은 구체적인 텍스트에서도 성공적으로 분할할 수 있음을 보였다.

이러한 SAM은 방대한 데이터로 훈련되어 다양한 하위 작업에 적응할 수 있는 모델이므로 Foundation Model의 정의에 맞는다.

다만 기존 모델들은 자기지도 학습을 강조했지만 SAM은 초기화에만 MAE를 사용했을 뿐 대부분 지도 학습을 이용했다.

SAM은 CLIP이 DALL-E의 구성 요소로 사용되듯 다른 시스템에서 조합될 수 있는 부품이 되는 것이 목표이다.

하지만 SAM은 다음과 같은 한계점을 가진다.

- 마스크에 대해서 아주 세밀한 구조를 놓치거나 경계선이 덜 깔끔할 수 있다.
- 마스크 디코더는 실시간으로 작동하지만 무거운 이미지 인코더를 포함한 전체 시스템은 실시간이 아니다.
- 다수의 점을 찍어 작업하는 전문적인 분할모델에 비교하면 성능이 떨어진다.
- 텍스트 프롬프트 기능은 아직 탐색적인 단계이고 완전히 안정적이지 않다.
- 의미 분할이나 파노라마 분할과 같은 복잡한 작업을 간단한 프롬프트로 구현할 지는 확실하지 않다.
- 의료 분석과 같은 특정 도메인에 고도로 특화된 전문 도구들이 해당 분야에서는 SAM보다 더 나은 성능을 보일 것이다.

하지만 SAM은 과제, 모델, 데이터 셋에 대한 제시를 통해 이미지 분할 기술을 파운데이션 모델로 끌어올리려는 시도였다.

이러한 SAM을 어떻게 활용하냐에 따라 미래를 여는 중요한 발판이 될 것이다.